Data Science & AI (TI) (CURPBATIN1810002024) Data Science & AI

Inhoudsopgave

0. Studiewijzer

Data Science Introductie TIAO

- 0.1. Doel en plaats van de cursus in het curriculum
- 0.2. Leerdoelen en competenties
- 0.3. Leerinhoud
- 0.4. Leermateriaal
- 0.5. Werkvormen
- 0.6. Werk- en leeraanwijzingen
- 0.7. Studiebegeleiding, vragen stellen
- 0.8 Planning
- 0.9. Evaluatie
- 1. Basisbegrippen, steekproefonderzoek
- 2. Analyse van 1 variabele
- 3. Kansrekening, de centrale limietstelling, statistische toetsen
- 4. Analyse van 2 kwalitatieve variabelen
- 5. Analyse van 2 variabelen: kwalitatief vs kwantitatief
- 6. Analyse van 2 kwantitatieve variabelen
- 7. Tijdserie-analyse

Voorbeeldexamen

Data Science & AI (Leerpad)

DIt leerpad bevat een overzicht van de cursus **Data Science & Al**. De inhoud zal in de loop van het semester verder aangevuld worden waar nodig.

Aan de linkerkant vind je een **inhoudstafel** met de studiewijzer en de 7 modules waaruit de cursus bestaat. Voor elke module vind je de **leerdoelen** terug (wat moet je kennen en kunnen?), verwijzingen naar **lesmateriaal** (slides, lesopnames, enz.) en **oefeningen**.

In dit leerpad vind je voor elke module een aantal **reflectie-oefeningen**. Deze zijn eerder gericht op het instuderen van de theorie en er een dieper inzicht in te verwerven, er zijn geen verregaande berekeningen nodig. Daarnaast zijn er voor elke module ook **laboopdrachten** voorzien waar je datasets zal analyseren met Python. Die labo-opdrachten zijn niet opgenomen in dit leerpad, maar ter beschikking gesteld via een publieke **Githubrepository**.

Feedback inhoud cursus, leerpad

Als je een **fout** vermoedt in de inhoud van het leerpad, de slides of ander lesmateriaal, of er is iets **onduidelijk**, aarzel niet dit te melden aan de lector die jouw klasgroep begeleidt, of aan de titularis van het vak, <u>Bert Van Vreckem (mailto:bert.vanvreckem@hogent.be?subject=%5BDSAl%5D%20Feedback%20leerpad&body=Beste%20meneer%20Van%20Vreckem%0A%0A).</u>



0. Studiewijzer (Sectie)

Studiewijzer

In de studiewijzer vind je alle praktische informatie en afspraken ivm het olod Data Science.

Lesopname VC - 24-25

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopname VC - 23-24

Cliquez pour vous connecter et lire la vidéo



Data Science Introductie TIAO (Video)



0.1. Doel en plaats van de cursus in het curriculum (Pagina)

Doel en plaats van de cursus in het curriculum

Deze cursus is een inleiding op wat tegenwoordig vaak data science genoemd wordt. Het doel is om je wegwijs te maken in het correct verzamelen, verwerken en analyseren van numerieke data. Je leert de juiste technieken toepassen om numerieke data samen te vatten en te visualiseren, en je leert hoe je kan nagaan in hoeverre er een verband bestaat tussen verschillende variabelen.

Succesvolle bedrijven nemen beslissingen, niet op basis van buikgevoel of intuïtie, maar door het verzamelen en analyseren van data. Aan de hand van de technieken die in deze cursus toegelicht worden, heb je voldoende achtergrond om vragen te beantwoorden als:

- Is een (web)applicatie snel genoeg voor de gebruikers? Is de gebruikerservaring consistent, of zit er grote variatie op responstijden?
- Wat is het effect van een wijziging aan de werking van een webshop, of de implementatie van een nieuwe feature? Leidt dit tot een hogere omzet?
- Als je twee systemen moet vergelijken, zij het software of hardware, welke van de twee is het meest performant? Is het verschil tussen beide significant, of kunnen verschillen in de metingen te wijten zijn aan het toeval of andere factoren?
- Wanneer moeten aankopen van nieuwe apparatuur (bv. harde schijven, servers, geheugen, enz.) ingepland worden, op basis van historische gebruiksgegevens?

De competenties die je in deze cursus verwerft hebben ook buiten de informatica hun nut. Je leert immers kritisch omgaan met data en informatie, en hoe die correct te analyseren en interpreteren. In het politieke en maatschappelijke debat worden moedwillig beweringen gedaan die aantoonbaar fout zijn of die de waarheid proberen "om te buigen." De term die in dat verband vaak de kop opsteekt is 'Fake News'. Grafieken die op het eerste zicht objectieve data tonen, worden zodanig gemanipuleerd dat ze toch een vertekend (of geheel foutief) beeld van de werkelijkheid geven. Een manier om je hiertegen te wapenen is kritisch omgaan met de informatie die verspreid wordt. Daardoor kan vaak de achterliggende reden van die desinformatie duidelijk gemaakt worden.

Statistiek en data science zijn dan ook onontbeerlijk om (i) te data correct te analyseren en tot onderbouwde conclusies te komen en (ii) zelf onderzoeken uit te voeren waarbij je onderbouwde conclusies de wereld kan in sturen.



0.2. Leerdoelen en competenties (Pagina)

Leerdoelen en competenties

Het doel van deze cursus is studenten vertrouwd te maken met statistische methoden voor het analyseren en visualiseren van data.

- Beschrijvende statistiek
 - o Kent enkele beschrijvende maten voor data.
 - Kan enkele beschrijvende maten voor data berekenen m.b.v. statistische software (Python).
 - o Kent verschillende soorten plots om data visueel voor te stellen.
- Kansrekening
 - o Kent de basisregels m.b.t. rekenen met kansen.
 - o Kent de eigenschappen van enkele belangrijke kansverdelingen.
- Analyse van 2 variabelen
 - Kan het verband tussen twee variabelen quantificeren en op de gepaste manier testen
 - Kan een eenvoudig lineair model opstellen om het verband tussen twee of meer variabelen weer te geven.
- Tijdserie-analyse
 - Kan enkele gangbare modellen bespreken om tijdsreeksen te gaan voorspellen en/of anomalieën te gaan detecteren.
 - Kan het belang duiden om de accuraatheid van een model op een methodologisch correcte manier te testen.



0.3. Leerinhoud (Pagina)

Leerinhoud

In **module 1** lichten we enkele *basisbegrippen* toe, zoals de wetenschappelijke methode, soorten onderzoek, variabelen en *meetniveaus*, enz. We bespreken ook hoe *steekproeven* genomen worden uit een populatie en welke fouten daarbij kunnen gemaakt worden.

In **module 2** starten we met een inleiding op beschrijvende statistiek, meer bepaald de *analyse van een variabele*. Dat omvat het berekenen van centrum- en spreidingsmaten (afhankelijk van het meetniveau van een variabele) en correcte vormen om kwalitatieve en kwantitatieve data te visualiseren.

Het centrale onderwerp in **module 3** is de *centrale limietstelling*, een essentieel concept binnen de statistiek, omdat het de voorwaarden bepaalt waaronder je meetresultaten op een steekproef ook kan extrapoleren naar de populatie als geheel. Het wiskundige bewijs van de centrale limietstelling zien we hier niet, maar om de betekenis en toepassingen ervan te begrijpen heb je wat kennis over *kansrekening* en stochastische verdelingen nodig. Eén van de belangrijkste toepassingen van de centrale limietstelling is de procedure van een *statistische toets*. In deze module lichten we het verloop van zo'n toets toe en passen dit toe op de zgn. *z*-toets en de *t*-toets.

In de volgende modules proberen we te zoeken naar verbanden tussen twee variabelen, d.w.z. of de waarde van één variabele (de afhankelijke) op een systematische wijze verandert ten opzichte van de waarde van een andere (de onafhankelijke). Dit is een eerste (maar zeker geen voldoende!) aanwijzing dat er een oorzakelijk verband kan bestaan tussen beide variabelen.

In **module 4** richten we ons op de situatie waar beide variabelen kwalitatief zijn. In dat geval kan je gebruik maken van de *chi-kwadraattoets* (χ^2 -toets) en *Cramér's V.* We zien ook manieren om dit soort data te *visualiseren*.

Als de onafhankelijke variabele kwalitatief is, en de afhankelijke kwantitatief, kan je de *ttoets voor twee steekproeven* gebruiken, en ook het concept van *effectgrootte*. Deze technieken worden in **module 5** toegelicht, naast geschikte *visualisatietechnieken* voor deze situatie

Module 6 gaat over *regressie-analyse*, wat typisch gebruikt wordt om een verband tussen twee kwantitatieve variabelen te onderzoeken. Ook hier kijken we naar geschikte *visualisatietechnieken*.

De **laatste module** staat qua onderwerp een beetje los van de rest van de cursus, maar is daarom niet minder belangrijk. Hier bespreken we de beginselen van *tijdserie-analyse*, wat ons in staat kan stellen om trends op te sporen en tot op zekere hoogte voorspellingen te doen.



0.4. Leermateriaal (Pagina)

Leermateriaal

Het studiemateriaal voor dit opleidingsonderdeel bestaat uit:

- Dit leerpad, met lesopnames voor elke module
- Uitleg + Python codevoorbeelden van de in de les behandelde onderwerpen, gepubliceerd als <u>Jupyter Notebook (https://jupyter.org)</u>-bestanden in een Githubrepository (zie hieronder)
- Labo-oefeningen, eveneens gepubliceerd in deze Github-repo
- Slides bij de lessen, gepubliceerd als PDF onder <u>Documenten</u>
 (https://chamilo.hogent.be/index.php2
 go=CourseViewer&application=Chamilo%5CApplication%5CWeblcms&course=59077&tool=Document).
- (aanvullend) een tweetalige (NL, EN) woordenlijst met de in de cursus gebruikte termen: https://hogenttin.github.io/dsai-glossary/) (https://hogenttin.github.io/dsai-glossary/)

Jupyter Notebooks zijn een webgebaseerde technologie waarbij opgemaakte tekst (Markdown), Python-code en uitvoer, data, afbeeldingen, enz. kunnen gecombineerd worden in één bestand. Voor het openen en bewerken van dit soort bestanden bestaan verschillende tools die je al kent. Lees verder voor meer info.

Github-repo voor codevoorbeelden en labooefeningen

Je kan codevoorbeelden en opgaven van oefeningen vinden in deze Github-repository: https://github.com/hogenttin/dsai-labs (<a href="h

We raden aan om hier een lokale kopie van te maken met Git clone via de HTTPS-url:



Op deze manier heb je meteen alle Jupyter Notebook-bestanden en datasets.

In de loop van het semester zullen er wellicht nog verbeteringen aangebracht worden aan het lesmateriaal. Je kan best bij het begin van elke les een terminal openen binnen je lokale kopie van de repo en met git pull de laatste wijzigingen binnen halen.

Merk op dat je als student geen schrijfrechten hebt op deze repository, dus eventuele lokale wijzigingen zal je niet kunnen pushen naar Github. We raden zelfs af om wijzigingen aan te brengen in deze repo, want dan zal je merge-conflicten veroorzaken als je jouw wijzigingen wil combineren met onze aanpassingen.

Hou dus je eigen nota's en uitgewerkte oefeningen apart bij, zoals hieronder beschreven.

Je kan ook de repo als een .zip downloaden, maar dan is het minder handig om wijzigingen in de loop van het semester bij te houden.

Software

Om het studiemateriaal te gebruiken en de oefeningen te maken, kan je kiezen tussen een cloud-omgeving (waar je geen software voor hoeft te installeren) of een lokale omgeving (waarvoor je Python en VSCode zal nodig hebben).

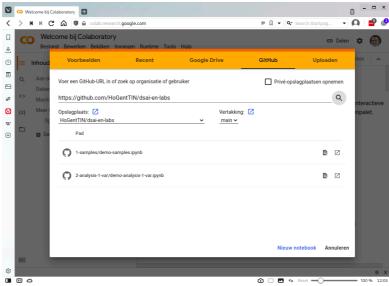
Hieronder vind je instructies om met beide aan de slag te gaan.

In de cloud

Je kan online werken met Jupyter Notebooks via het platform <u>Google Colab</u> (https://colab.research.google.com), en hoeft daar dan ook geen extra software voor te installeren. Hiervoor is echter wel een **Google-account** nodig.

1. Zorg dat je ingelogd bent op Google en surf naar https://colab.research.google.com). (https://colab.research.google.com).

2. Je krijgt een pop-up te zien om een notebook te openen. Klik op het tabblad "Github":



3. In het invulvak "Voer een Github-URL in", kan je deze URL

plakken: https://github.com/HoGentTIN/dsai-labs

(https://github.com/HoGentTIN/dsai-labs)

- Je krijgt een overzicht te zien van alle Jupyter Notebooks binnen deze repository. Klik de gewenste aan om te openen.
- 5. Maak tenslotte een kopie voor jezelf (bv. in Google Drive) waar je je eigen wijzigingen kan in opslaan. Dit kan via het menu "Bestand" bovenaan de pagina.

Google Colab maakt een subdirectory "Colab Notebooks" aan op jouw Google Drive. Daar kan je nog een subdirectory "data" aan toevoegen om alle databestanden die in de oefeningen gebruikt worden in op te slaan.

! Let op! Oude versies van Python libraries op Google Colab

Op de Google Colab-omgeving staan oudere versies geïnstalleerd van de Python libraries die je nodig hebt voor de labo-oefeningen. Meestal is dat geen probleem, maar soms krijg je toch fouten, bv. over een onbestaande parameter die in die oudere versie nog niet bestond . De oplossing is om bij het begin van een Notebookbestand een nieuw codeblok toe te voegen met als inhoud:

```
!pip install --upgrade matplotlib
!pip install --upgrade scipy
!pip install --upgrade statsmodels
```

Je hoeft dit enkel te doen in de Notebooks waar je fouten tegenkomt en enkel voor de libraries waar de fout zich voordoet.

Op eigen laptop

Als je het voor jezelf nuttig vindt om op je eigen laptop te werken, dan kan dat ook (maar het is niet vereist om deze cursus met succes af te werken). In dat geval heb je volgende software nodig:

- Python
- Visual Studio Code, met extensies:
 - o Python, Pylance (Microsoft)
 - o Jupyter, Jupyter Keymap, Jupyter Notebook Rendering (Microsoft)
 - o Optioneel: GitLens (GitKraken), Markdown All in One (Yu Zhang)
- Git & een Github-account (we veronderstellen dat je hier al over beschikt)

Installeer de software op Windows bv. met winget (in een CMD of PowerShell terminal met Administrator-rechten):

```
> winget install Python.Python.3.12
> winget install Microsoft.VisualStudioCode
```

Gebruikers van Linux en macOS kunnen de respectievelijke package managers van hun OS (apt, dnf, HomeBrew, ...) gebruiken voor de installatie. Op Linux is Python ongetwijfeld reeds geïnstalleerd en hoef je dus enkel naar de <u>website van VSCode</u>

(https://code.visualstudio.com/#alt-downloads) gaan en de package voor jouw distributie te installeren.

Maak een nieuwe directory aan waarin je je oefeningen en nota's wilt bijhouden. Kopieer vanuit je lokale kopie van onze Github-repo dsai-labs de directories " data " en " 1-samples " naar deze nieuwe map. Open de directory in VSCode. Als je een Jupyter Notebook-bestand (met extensie .ipynb) opent, zal Code je aanbieden om de nodige extensies te installeren. Verdere instructies vind je in de Notebook-bestanden onder "1-samples".

Je kan in deze directory zelf ook een Git repo initialiseren en eventueel koppelen aan een nieuwe (private!) repository onder je eigen account op Github.

Achtergrondinformatie

Wie interesse heeft in een boek dat (min of meer) overeenkomt met de inhoud van deze cuirsus, verwijzen we naar:

Rajagopalan, G. (2021) A Python Data Analyst's Toolkit: Learn Python and Python-based Libraries with Applications in Data Analysis and Statistics. Springer.

https://link.springer.com/book/10.1007/978-1-4842-6399-0

(https://link.springer.com/book/10.1007/978-1-4842-6399-0)

Je kan dit boek vanop de HOGENT-campus (of via VPN) gratis als e-book (pdf of epub) downloaden via de link.

Let op: in deze cursus volgen dat boek niet van begin tot einde, maar je zal wel verschillende topics uit de cursus in het boek terugvinden.

Verder kan ook de API-documentatie van de gebruikte Python-packages van pas komen, bv.

- Pandas (https://pandas.pydata.org/docs/index.html)
- Matplotlib (https://matplotlib.org/stable/api/)
- Seaborn (https://seaborn.pydata.org/api.html)
- SciPy (https://docs.scipy.org/doc/scipy/)
- Scikit-learn (https://scikit-learn.org/stable/api/index.html)
- ...



0.5. Werkvormen (Pagina)

Studenten van het dagonderwijs krijgen **drie uur per week** les. Deze lessen bestaan afwisselend uit **klassikale instructie** met oefeningen en **labo-opdrachten** waar je datasets zal analyseren en visualiseren aan de hand van **Python**



0.6. Werk- en leeraanwijzingen (Pagina)

Werk- en leeraanwijzingen

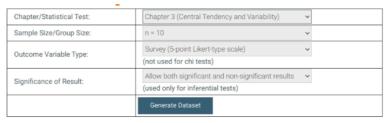
De inhoud van het opleidingsonderdeel *Data Science & Al* wordt door veel studenten als moeilijk ervaren. Dat is begrijpelijk, want het onderwerp ligt dan ook buiten de comfortzone van de doorsnee informaticastudent en we weten allemaal dat wiskundige vakken niet de populairste van onze opleiding zijn.

Er zijn twee manieren om hier mee om te gaan. Je kan de weg van de minste weerstand nemen: je concentreren op de vakken die je graag doet en een dag voor het examen de cursus doornemen in de hoop dat je voldoende punten bij elkaar sprokkelt om een tien te halen. De ervaring leert dat deze strategie niet succesvol is. In de eerste zittijd slaagde in het verleden typisch slechts een derde van de studenten. In de tweede zittijd zien we vaak een veel hoger slagingspercentage, wat naar onze mening suggereert dat wanneer je voldoende inspanning levert voor dit vak, het zeker haalbaar is.

Enkele tips om wél meteen te slagen voor dit vak:

- Volg de lessen en neem actief nota's (Lundin, 2020);
 - Onderschat de waarde van handgeschreven nota's niet! Breng papier en schrijfgerief mee!
 - Elektronische nota's neem je best in een Jupyter Notebook. Je kan er Pythoncode afwisselen met tekst in Markdown-formaat
 (https://docs.github.com/en/get-started/writing-on-github/getting-startedwith-writing-and-formatting-on-github/basic-writing-and-formatting-syntax).
 Voor wiskundige formules kan je LaTeX-syntax
 (https://www.overleaf.com/learn/latex/Mathematical_expressions) gebruiken
 (zie de demo-notebooks voor voorbeelden!).
- Werk ook voor dit vak buiten de contactmomenten. Herhaal de geziene theorie en werk oefeningen af waarmee je nog niet klaar was. Noteer zaken die je niet begrijpt of waar je vast zit, en stel je vraag tijdens het eerstvolgende contactmoment.
- Gebruik goede leertechnieken. Download vrijblijvend het gratis e-boek (<u>Leer studenten</u>) Studeren Met Succes (https://thomasmore.be/nl/onderwijs-en-leren/leer-studenten-studeren-met-succes) van Tine Hoof, et al. Je vindt er een goed overzicht van leertechnieken waarvan het effect wetenschappelijk aangetoond is, bv:
 - Spaced practice: Studeer in meerdere kleine sessies (minstens één keer per week) en niet in grote blokken. Blokkeer een vast moment in je weekagenda/lesplanning!
 - Retrieval practice: Neem een leeg blad papier en probeer zoveel mogelijk zaken over een bepaald onderwerp op te schrijven vanuit je herinnering (dus zonder in de cursus te kijken). Controleer dit daarna aan de hand van je lesnota's en in de cursus.
 - Elaboration: Stel jezelf vragen over hoe dingen (bv. formules, toetsingsprocedures,...) in elkaar zitten en waarom dat zo is. Overleg met medestudenten. Vraag je lector om meer uitleg indien nodig. Leg verbanden tussen verschillende onderwerpen in de cursus (bv. vergelijk toetsingsprocedures).
 - o Interleaving: Wissel onderwerpen af tijdens het studeren.
 - Gebruik concrete voorbeelden om abstracte ideeën te begrijpen. In de cursus worden reeds enkele voorbeelden gegeven, probeer er zelf andere te bedenken. Overleg met medestudenten en vraag eventueel feedback aan je lector.
 - Dual coding: Combineer woord en beeld, probeer de leerstof die je instudeert visueel voor te stellen.
- Zorg dat je de inhoud van demo-notebooks begrijpt en alle labo-oefeningen kan maken. Maak de oefeningen eens opnieuw!
- Als je extra oefeningen wilt mét oplossingen, kan je eens kijken naar de website van Richard Landers: https://rlanders.net/dataset-generator/).

Dataset Generator Settings



In de dropdown bovenaan kan je een onderwerp kiezen. Behalve "Chapter 10 - ANOVA" zijn *alle* gegeven onderwerpen in onze cursus aan bod gekomen!

! Valkuil

Uiteindelijk komt het er op neer dat je voldoende tijd en inspanning investeert om te studeren voor dit vak. Dat leren moeilijk en lastig is, is normaal. Als alles vanzelf gaat heb je eigenlijk niets bijgeleerd. Groeien doe je enkel buiten je comfort-zone!



0.7. Studiebegeleiding, vragen stellen (Pagina)

Studiebegeleiding, vragen stellen

- Het eerste aanspreekpunt bij moeilijkheden bij of vragen over deze cursus is de lector bij wie je de lessen volgt, of desgevallend de begeleider voor afstandsleren (TIAO).
 Stel je vragen bij voorkeur tijdens de contactmomenten, hetzij de wekelijkse lessen voor dagonderwijs, hetzij de contactavonden voor afstandsleren.
- Als je niet de kans krijgt om je vragen te stellen tijdens een contactmoment, kan je
 deze stellen via MS Teams. Er is een algemeen Team aangemaakt waar elke student
 die dit vak volgt op ingeschreven is. Je vindt de link vanaf de hoofdpagina van de
 Chamilo-cursus, het icoontje/link aan de rechterkant.
- Stel a.u.b. geen vragen via e-mail of Teams chat, tenzij het om persoonlijke aangelegenheden gaat. We willen alle vragen over de vakinhoud bundelen via Teams, zodat het antwoord meteen voor iedereen beschikbaar is en we niet telkens dezelfde vragen moeten beantwoorden.
- Heb je een fout gevonden in de slides of ander lesmateriaal? Laat het weten aan <u>Bert Van Vreckem (mailto:bert.vanvreckem@hogent.be?</u> <u>subject=%5BDSAI%5D%20Feedback%20lesmateriaal&body=Beste%20meneer%20Van%20Vreckem%0A%0A)</u>. Fouten of suggesties voor het studiemateriaal en de labo-opdrachten die via Github aangeboden worden kunnen <u>via een Issue (https://github.com/HoGentTIN/dsai-en-labs/issues)</u> gemeld worden. Alvast bedankt dat je de tijd neemt om deze te melden!

Contactinfo lectoren

Dit zijn de lectoren voor het vak, de groepen die ze begeleiden en wanneer het geroosterde contactmoment doorgaat.

We herhalen dat je de lectoren enkel per email contacteert als het gaat om een persoonlijke aangelegenheid. Vragen over de vakinhoud kan je via Teams stellen (zie hierboven).

- Sabine De Vreese (mailto:sabine.devreese@hogent.be? subject=%5BDSAI%5D&body=Beste%20mevrouw%20De%20Vreese%0A%0A):
 - o Gent
 - o English taught, IC
 - Vaktitularis
- <u>Lieven Smits (mailto:lieven.smits@hogent.be?</u>
 <u>subject=%5BDSAl%5D&body=Beste%20meneer%20Smits%0A%0A)</u>
 - Gent
- Pieter Van Der Helst (mailto:pieter.vanderhelst@hogent.be? subject=%5BDSAI%5D%20&body=Beste%20meneer%20Van%20Der%20Helst):
 - Gent
- Bert Van Vreckem (mailto:bert.vanvreckem@hogent.be? subject=%5BDSAI%5D%20&body=Beste%20meneer%20Van%20Vreckem%0A%0A):
 - Aalst
 - o Gent
 - o TIAO
 - o VC



0.8 Planning (Pagina)

Planning

De tabel hieronder bevat een overzicht van de lesplanning voor het dagonderwijs. Merk op dat deze kan afwijken van de realiteit, bv. wanneer er door een officiële feestdag of andere omstandigheden een contactmoment wegvalt.

Wee	Week <mark>Onderwerp</mark>			
1	Intro, studiewijzer, steekproefonderzoek			
2				
3	Analyse van 1 variabele			
4				
5	Kansrekening en de Centrale Limietstelling			
6	Toetsingsprocedures: de z-toets			
7	Toetsingsprocedures: de <i>t</i> -toets			
8	Analyse van twee kwalitatieve variabelen: chi-kwadraattoets en Cramér's V			
9	Analyse van kwalitatieve vs kwantitatieve variabelen: <i>t</i> -toets voor 2 steekproeven, effectgrootte			
10	Analyse van 2 kwantitatieve variabelen: regressie-analyse			
11	Tijdreeksen			
12	Inhaal- en herhalingssessie			



0.9. Evaluatie (Pagina)

Evaluatie

- Eerste examenkans:
 - 100% Schriftelijk examen op PC (eigen laptop), met hulpmiddelen (zie hieronder)
- Tweede examenkans:
 - o idem

Voorbeeldexamen

Je kan een voorbeeldexamen vinden in de Github-repo voor de labo-opgaven, onder de directory <u>RepeatExercises</u> (https://github.com/HoGentTIN/dsai-labs/tree/main/RepeatExercises).

Hulpmiddelen

Op het examen mogen volgende hulpmiddelen mag gebruiken (zowel elektronisch in de browser of omgezet naar PDF als afgedrukt/op papier):

- Slides en ander op Chamilo gepubliceerd lesmateriaal
- De nodige software voor statistische analyse: Python, VS Code
- De Python voorbeeldcode (demo-*.ipynb) in de Github-repository voor de laboopgaven
- Eigen nota's en oplossingen van labo's en oefeningen
- Code snippets in je IDE (die je zelf geschreven hebt)
- Gebruik van internet is ook toegelaten, tenzij wat hieronder opgesomd wordt

Zorg dat je laptop correct geconfigureerd is zodat je meteen aan het examen kan starten. Technische problemen met de te gebruiken software zijn voor jouw rekening.

Elke vorm van communicatie met medestudenten of derden is uiteraard verboden. Dus geen:

- GSM, smartphone of smartwatch
- Hoofdtelefoon, bedrade of bluetooth oortjes (oordoppen of oorbeschermers zonder elektronica kunnen wel)
- Communicatie-apps als Discord, Messenger, WhatsApp, Teams, e-mailclient, chatapplicaties, enz. Vergeet niet om alle desktop-meldingen UIT te zetten, want ook binnenkomende meldingen worden als communicatie beschouwd.
- Websites die communicatie toelaten, bv. Facebook, Q&A sites als StackOverflow,
 Forums, enz. (kom je op het examen via een zoekopdracht toch per ongeluk terecht
 op zo'n website, sluit meteen het tabblad/venster).
- Large Language Models zoals ChatGPT, LLama, Copilot Chat, Bing Chat, Google Bard/Gemini, enz. Ook het gebruik van Github Copilot is verboden.
- Andere applicaties, websites, enz. waarmee je het beantwoorden van de examenvragen uitbesteedt aan een externe partij (bv Mechanical Turk).
- Elke andere vorm van communicatie of werkwijze waardoor je examenvragen niet zelf beantwoordt die niet hierboven opgesomd is.

Examenrichtlijnen

- De totaalscore die je behaalt voor dit examen wordt herrekend naar een examencijfer op 20.
- Het examen duurt twee uur (tenzij je extra tijd krijgt als IOEM examenmaatregel)
- Alle studenten (VC én on-campus) maken een opname van het examen die meteen na het examen gedeeld wordt via Panopto met de lector van de klasgroep waar je ingeschreven bent.
 - Voor het on-campusexamen volstaat een opname van je scherm en de ingebouwde webcam van je laptop. VC moeten daarboven ook de werkplek filmen via een externe webcam.
 - Verder gelden alle <u>richtlijnen voor Panopto-opnamen van examens</u>
 (https://chamilo.hogent.be/index.php?
 go=CourseViewer&application=Chamilo%5CApplication%5CWeblcms&course=11613&tool=Announcement&brov
 Lees deze goed na en volg de instructies strikt op. Bereid je al voor door vooraf
 een map aan te maken met de juiste naam en te delen met de juiste lector.
- De opgave download je van exam.hogent.be als een Jupyter Notebook (.ipynb).

- Hernoem het Jupyter Notebook bestand dsai-2324-ReeksX-FAMILIENAAM-VOORNAAM.ipynb voordat je het opent, vervang FAMILIENAAM en VOORNAAM door jouw naam.
- Vul in de eerste Markdown-cel je naam, studentennummer, examendatum en -uur en klasgroep in. Als je een IOEM-student bent, geef dat dan ook aan.
- Voeg waar nodig codecellen toe voor het uitwerken van de vragen.
 - TIP! Vermijd het hergebruik van algemene variabelennamen (bv. data, df, ...)
 tussen verschillende vragen, maar gebruik waar mogelijk beschrijvende namen
 (bv. penguins, agri_businesses, aus_athletes, enz.). Als je tijdens het examen
 wisselt tussen het werken aan verschillende vragen, zou je immers variabelen
 kunnen overschrijven en zo verkeerde resultaten of runtime errors kunnen
 bekomen.
- LET OP! Alleen wat je in de daarvoor voorziene Markdown-cellen noteert telt als antwoord! De inhoud van de codeblokken dient enkel om je antwoord te staven, zodat we kunnen zien hoe je tot je antwoord gekomen bent als het niet zou overeenkomen met de verwachte uitkomst.
- Als het antwoord op een vraag een reëel getal is, rond dat telkens af tot exact vier cijfers na de komma, tenzij er expliciet iets anders gevraagd wordt. Zeer kleine getallen kunnen in wetenschappelijke notatie geschreven worden (bv. 1.2345e-6 of 1.2345x10^-6)

Indienen:

- Je dient het Notebook-bestand (ipynb, met jouw naam in de bestandsnaam!) in via exam.hogent.be. Niet inpakken in een .zip/.rar, of in een ander bestandsformaat indienen!
- Zorg er meteen na het examen voor dat je Panopto-opname opgeladen is, de juiste naam heeft en gedeeld is met de juiste lector.
- Studenten die het examen on-campus afleggen moeten tekenen voor aanwezigheid.

! LET OP!

Wanneer je inzending onvolledig is (Notebook, Panopto-opname en/of handtekening op aanwezigheidslijst), kan je niet aantonen dat je het examen op een correcte en eerlijke manier hebt afgelegd. In dat geval is het voor ons ook niet mogelijk om je te beoordelen en krijg je als examencijfer 0/20.

Online-examen (VC)

Voor studenten VC gelden de algemene regels en afspraken voor online examens. Lees deze nog eens goed na en pas de richtlijnen strikt toe!

Stuit je tijdens het examen op een probleem waardoor je niet verder kan? Dan mag je via Teams contact opnemen met de lector die jouw klasgroep begeleid heeft. Voor technische problemen volg je de instructies in het document "<u>Ferste hulp bij digitale paniek (https://www.hogent.be/sites/hogent/assets/File/Panic%20Card_studenten.pdf)</u>".



1. Basisbegrippen, steekproefonderzoek (Sectie)

Leerdoelen

Na dit hoofdstuk moet je in staat zijn om:

- De volgende basisbegrippen te definiëren
 - o variabele, waarde
 - o meetniveau: nominaal, ordinaal, interval, ratio
 - o populatie, steekproef, steekproefkader
 - o aselecte vs. selecte steekproef
 - o representatiteit van een steekproef
- De vier meetniveaus op te sommen, de kenmerken van elk te formuleren en een voorbeeld te geven;
- Voor een gegeven variabele het meetniveau te bepalen;
- De types steekproeffouten op te sommen, de kenmerken van elk te formuleren en een voorbeeld te geven;
- Uit een beschrijving van een steekproefmethode:
 - o een onderscheid te maken tussen een aselecte en selecte steekproefmethode;
 - o het type steekproeffout(en) dat gemaakt werd te benoemen en uit te leggen;
 - o voorstellen tot verbetering van de steekproefmethode te bedenken.

Lesopnames

AJ 24-25

Basisbegrippen en steekproefonderzoek

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Toelichting bij de labo-opgaven van dit hoofdstuk:

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Uitgewerkte oefening: lab-1.01-ais.ipynb

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

AJ 23-24

Hoofdstuk 1: vanaf ca. 40 minuten



2. Analyse van 1 variabele (Sectie)

Leerdoelen

Na dit hoofdstuk moet je in staat zijn om:

- Voor elk meetniveau de geschikte centrum- en spreidingsmaten te benoemen;
- De formules voor gemiddelde, variantie en standaardafwijking van een steekproef te reproduceren en te begrijpen;
- Van een gegeven variabele de centrum- en spreidingsmaten te berekenen;
- Voor elk meetniveau geschikte visualisatietechnieken te benoemen;
- Voor een gegeven variabele geschikte visualisatietechnieken toe te passen;
- Een gegeven grafiek te interpreteren, o.a. het grafiektype benoemen, centrum- en spreidingsmaten afleiden.

Overzicht centrum- en spreidingsmaten

Meetniveau	Centrummaten	Spreidingsmaten	
Kwalitatief	Modus	/	
Kwantitatief	Gemiddelde	Variantie, standaardafwijking	
Kwantitatiei	Mediaan	Bereik, interkwartielafstand	

Geschikte centrum- en spreidingsmaten voor elk meetniveau. De centrummaat en bijhorende spreidingsmaat worden vaak gebruikt als samenvatting voor de resultaten van de groep als geheel.

Overzicht visualisatietechnieken

Meetniveau	Grafiektypes
Kwalitatief	Staafdiagram van frequenties
	Boxplot
Kwantitatief	Histogram
	Dichtheids diagram

Geschikte grafiektypes per meetniveau voor het visualiseren van één variabele.

Lesopnames 2025

Analyse van 1 variabele - deel 1 (opname werd onderbroken)

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Analyse van 1 variabele - deel 2

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Datavisualisatie van 1 variabele

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Demo labo-oefeningen 2.01 (metro: verschil tussen berekening Q1, Q3 door numpy en wat in de slides staat); 2.03 (kitten litters: hoe omgaan met een frequentietabel bij de berekening van centrum- en spreidingsmaten)

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopnames 2024

Theorie + Demo

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Oefeningen

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Opmerking ivm Oefening 2.03

lpv de Python functie zip te gebruiken, kan je ook gebruik maken van np.repeat (Bart Heerkens)

```
[42] arr = np.repeat(kittens["Number in litter"], kittens["Frequency"])

print(f"Median: {arr.median()}")
print(f"Mean: {arr.mean()}")
print(f"Lower Quartile: {arr.quantile(0.25)}")
print(f"Upper Quartile: {arr.quantile(0.75)}")

Median: 4.0
Mean: 4.128205128205129
Lower Quartile: 3.0
Upper Quartile: 5.0
```

Lesopnames 2023

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lab 2.03



3. Kansrekening, de centrale limietstelling, statistische toetsen (Sectie)

Leerdoelen

Na het studeren van dit hoofdstuk ben je in staat om:

- Kansrekening:
 - de basisbegrippen voor kansrekening uit te leggen (kansruimte, gebeurtenis, uitkomst, waarschijnlijkheidsruimte)
 - de (standaard)normale verdeling te schetsen en de eigenschappen toe te lichten
 - o een z-score te berekenen
 - kansen in een (standaard)normale verdeling te berekenen (linkerstaartkans, rechterstaartkans)
- De centrale limietstelling
 - de centrale limietstelling te formuleren en het belang voor statistische analyse toe te lichten
 - o betrouwbaarheidsintervallen te berekenen voor het gemiddelde van een grote of kleine steekproef
- Statistische toetsen:
 - de basisbegrippen voor statistische toetsen uit te leggen (toets, nulhypothese, alternatieve hypothese, steekproefgrootheid, significantieniveau, overschrijdingskans, aanvaardings- en kritieke gebied, ...)
 - o de procedure van een statistische toets op te sommen en toe te lichten
 - o een z-toets en t-toets uit te voeren op een dataset.
 - o voor een gegeven situatie de correcte variant van z- of t-toets te kunnen kiezen
 - o de mogelijke fouten (type I, type II) bij hypothesetoetsen te kunnen toelichten

Lesopnames 2025

Kansrekening - deel 1

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Kansrekening - deel 2 - verwachte waarde en variantie van een (discrete) kansvariabele.

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Kansrekening - deel 3: continue kansvariabelen

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

De centrale limietstelling (CLT) en betrouwbaarheidsintervallen (CI)

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Herhaling: CLT en Cl, uitgewerkte oefeningen berekenen Cl

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Hypothesetoetsen, de z-toets

Hypothesetoetsen: de t-toets; fouten in hypothesetoetsen (Type I, Type II); uitgewerkte oefeningen z-/t-toets (op basis van rlanders.net/dataset-generator)

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopnames 2024

Demo 3.01 probability

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Oefeningen 3.01 - probability

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Demo 3.02 Central Limit Theorem + Confidence Intervals

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Herhaling CLT + oefeningen CLT en confidence intervals + Uitleg statistiche toetsen

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Oefeningen statistische toetsen



4. Analyse van 2 kwalitatieve variabelen (Sectie)

Leerdoelen

Na instuderen van dit hoofdstuk ben je in staat om:

- de basisbegrippen van analyse van 2 variabelen uit te leggen: een statistisch verband tussen 2 variabelen, afhankelijke/onafhankelijke variabele
- toe te lichten waarom een verband niet noodzakelijk een causale relatie impliceert
- twee kwalitatieve variabelen op een correcte manier te visualiseren
- een kruistabel op te stellen voor 2 kwalitatieve variabelen
- de statistieken χ^2 en Cramér's V te berekenen
- de χ²-onafhankelijkheidstoets uit te voeren
- de χ^2 -aanpassingstoets (goodness-of-fit test) uit te voeren
- gestandaardiseerde residuën te berekenen
- de regels van Cochran toe te lichten en controleren of ze voldaan zijn in een gegeven casus

Samenvatting analyse van 2 variabelen

Onafhankelijke	Afhankelijke	Statistiek/toets
Kwalitatief	Kwalitatief	χ²-toets
Kwaiitatiei	Kwaiitatiei	Cramér's V
Kwalitatief	Viviantitatiof	t-toets voor 2 steekproeven
Kwaiitatiei	Kwantitatief	Cohen's d (effectgrootte)
wantitatief Kwantitatief		Lineaire regressie, correlatie

Onafhankelijke	Afhankelijke	Grafiektype
Kwalitatief	Kwalitatief	Geclusterd staafdiagram, mozaïekdiagram
Kwalitatief	Kwantitatief	Boxplot, staafdiagram met error bars
Kwantitatief	Kwantitatief	Spreidings diagram, regressierechte

Lesopnames 2024

Slides

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Oefeningen

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopnames 2023

Slides

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Slides (Herhaling) + Demo + Lab 1

Lesopnames 2022

Slides + demo

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Labo



5. Analyse van 2 variabelen: kwalitatief vs kwantitatief (Sectie)

Leerdoelen

Na het verwerken van deze module kan je:

- Geschikte technieken gebruiken om het verband tussen een kwalitatieve en kwantitatieve variabele te visualiseren
 - o Gegroepeerde boxplot, kansdichtheidsplot, violin plot
 - o Staafdiagram met error bars
- De t-toets voor 2 gepaarde of onafhankelijke steekproeven toepassen
- Effectgrootte (Cohen's d) berekenen

Lesopnames 2024

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopnames 2023



6. Analyse van 2 kwantitatieve variabelen (Sectie)

Leerdoelen

Na het verwerken van deze module kan je:

- Geschikte technieken gebruiken om het lineaire verband tussen twee kwantitatieve variabelen te visualiseren:
 - o Spreidingsdiagram
 - o Regressierechte
- De parameters van een regressierechte (richtingscoëfficiënt en snijpunt met de y-as) berekenen
- Covariantie, correlatie- en determinatiecoëfficiënt berekenen en de waarde ervan interpreteren.

Lesopnames 2024

Hoofdstuk 6 Begin

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Hoofdstuk 6 met oefeningen

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopnames 2023



7. Tijdserie-analyse (Sectie)

Leerdoelen

Na het verwerken van deze module kan je:

- Een tijdserie visualiseren met Python
- Het concept van een tijdseriemodel toelichten
- Het eenvoudig voortschrijdend gemiddelde (simple moving average, SMA) van een tijdserie berekenen
- Een geschikte variant van exponentiële afvlakking toepassen op een tijdserie en voorspellingen (forecast) doen op basis van het opgebouwde model:
 - o Enkelvoudige exponentiële afvlakking (Single Exponential Smoothing)
 - Dubbele exponentiële afvlakking (Double Exponential Smoothing) of de methode van Holt voor tijdreeksen met een stijgende of dalende trend
 - Driedubbele exponentiële afvlakking (Triple Exponential Smoothing) of de methode van Holt-Winters voor tijdreeksen met een seizoenale trend
- De kwaliteit van een tijdseriemodel beoordelen op basis van gemiddelde gekwadrateerde fout (Mean Squared Error) of gemiddelde absolute fout (Mean Absolute Error).

Lesopnames 2024

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Demo + oefening 1 + 3

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Herhaling Theorie + oefening 2 + 4 +5 + 6 + 7

Lesopnames 2023

2023 slides

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

2023 slides + demo

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

2023 demo [scherm vergeten te delen] + exercises

Lesopnames 2022

Time series Demo 3

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Time Series Lab Covid Part 1

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Time series Lab Covid Part 2

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Time series Lab Golden Cross



Voorbeeldexamen (Sectie)

Lesopname 2024

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopname 2023

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

Lesopname 2022

Hier staat inhoud die niet geprint of offline gebruikt kan worden. Gelieve de webpagina te bezoeken met behulp van onderstaande QR-code om de volledige inhoud te bekijken.

!Fout op 1:15! Het moet zijn p-waarde is >>> 5% => er is niet voldoende bewijs om H0 te verwerpen.

